

Predicción de Emisiones de

CO2 en

Vehículos

Índice

1. Resumen
2. Introducción
3. Descripción de la Solución
4. Experimentación
5. Resultados
6. Conclusiones
7. Referencias
8. Anexo

1. Resumen

Se desarrolló un modelo de aprendizaje automático para clasificar vehículos en categorías de emisiones de CO₂. Partiendo de un dataset con 7,385 registros de vehículos, se realizó una limpieza detectando y eliminando 1,103 duplicados, quedando 6,282 registros válidos. El problema se transformó de regresión numérica a clasificación en 7 categorías de impacto ambiental. Se probaron cuatro algoritmos distintos obteniéndose como mejor modelo un Árbol de Decisión con 95.86% de precisión en validación.

2. Introducción

Motivación

La predicción de emisiones de CO₂ en vehículos es un problema relevante para clasificación ambiental y regulaciones gubernamentales. Siendo capaces de estimar el impacto ambiental de un vehículo basándose en sus características técnicas, podría automatizarse el proceso de etiquetado sin necesidad de pruebas exhaustivas.

Objetivo

Desarrollar un modelo de clasificación que prediga las emisiones de CO₂ en vehículos agrupándolas en categorías de impacto ambiental, basándose en especificaciones técnicas como cilindrada, cilindros, tipo de transmisión, consumo de combustible y tipo de combustible.

3. Descripción de la Solución

3.1 El Dataset

El dataset utilizado es un conjunto de datos de vehículos con información técnica y de consumo, como la marca, clase del vehículo, tipo de transmisión, tipo de combustible, cilindrada, número de cilindros y consumo de combustible en ciudad, carretera y combinado. A partir de la variable original de emisiones de CO2 se creó una nueva etiqueta categórica por rangos para convertir el problema en uno de clasificación.

3.2 Limpieza y Preparación

Detección de Duplicados

En el análisis exploratorio se identificaron **1,103 filas duplicadas**, representando el 14.97% del dataset total. Estos duplicados pueden sesgar el entrenamiento del modelo y perjudicar la precisión real, por lo que fueron eliminados completamente. Después de la limpieza: **6,282 registros válidos de 7385 registros originales**

División de Datos

El dataset se divide en 2 partes:

- El 80% de los datos será empleado para el entrenamiento de los modelos
- El 20% de los datos será utilizado para la prueba de rendimiento

Selección de Variables

Se eliminaron tres columnas del modelo original:

1. **Modelo:** Contenía miles de valores únicos distintos. Para incluirla habría que crear miles de columnas binarias durante la codificación, ralentizando excesivamente el entrenamiento sin aportar valor predictivo adicional. La información relevante ya está capturada en marca y clase de vehículo.
2. **Fuel Consumption Comb (mpg):** Representa la misma información que Fuel Consumption Comb (L/100 km) pero en unidades diferentes. Mantener ambas crearía redundancia innecesaria.
3. **CO2 Emisiones (g/km):** Al transformar a un problema de clasificación, era necesario eliminar la variable numérica original para evitar que el modelo tuviera acceso directo al valor que intentamos predecir.

3.3 Transformación del Problema

Se convirtió en un problema de regresión (predecir valor exacto en g/km). Las variables categóricas (marca, clase, transmisión, tipo combustible) se transformaron usando OneHotEncoder eliminando la primera categoría de cada grupo para evitar multicolinealidad.

Resultado final: **91 columnas** (9 numéricas originales + 82 binarias derivadas)

4. Experimentación

4.1 Selección de Modelos

Se eligieron cuatro algoritmos representativos:

- **Decision Tree (Árbol de Decisión):** Modelo basado en reglas lógicas caracterizado por su interpretabilidad. Divide el espacio de datos recursivamente creando condiciones sobre las variables.
- **Random Forest:** Modelo de ensamble que combina múltiples árboles de decisión, mejorando precisión y reduciendo sobreajuste respecto a árboles individuales. Cada árbol vota en la clasificación final.
- **K-Nearest Neighbors (KNN):** Algoritmo basado en proximidad geométrica. Clasifica un punto según la mayoría de votos de sus K vecinos más cercanos en el espacio de características.
- **Regresión Logística:** Modelo lineal clásico que estima probabilidades mediante función logística. Sirve como referencia base para este tipo de problemas.

4.2 Comparativa de Resultados

La comparativa de modelos mostró que los métodos basados en árboles fueron claramente los más eficaces para este problema: el Decision Tree y el Random Forest obtuvieron los mejores resultados, con una precisión cercana al 96%, lo que indica que capturan mejor la relación no lineal entre las variables técnicas del vehículo y las emisiones de CO2. Los mejores resultados se obtienen con modelos basados en árboles porque capturan bien relaciones no lineales e interacciones entre variables como cilindrada, tipo de combustible y consumo. La Regresión Logística mostró un **ConvergenceWarning** tras alcanzar 1,000 iteraciones sin converger. En consecuencia, el problema no parece linealmente separable y los árboles son más adecuados para este dataset, ya que logran mayor precisión y mejor adaptación a la estructura de los datos.

5. Resultados

5.1 Ranking Final

Ranking	Modelo	Precisión
1	Decision Tree	95.86%
2	Random Forest	95.78%
3	KNN	90.29%
4	Regresión Logística	89.74%

El Árbol de Decisión es el modelo ganador con la máxima precisión e interpretabilidad .La matriz de confusión mostró: total de errores: 52 de 1,257 (4.14%)

5.2 Variables Influyentes

El análisis de importancia reveló que:

- **Consumo combinado de combustible: 80.54%** - Factor dominante. Tiene sentido físico: más combustible quemado = más CO2.
- **Resto de variables: <5% cada una** - Aportan información marginal.

Esto valida que el consumo es prácticamente el único determinante de las emisiones.

6. Conclusiones

Hallazgos Principales

1. El Árbol de Decisión proporciona solución prácticamente óptima con 95.86% de precisión
2. La no-linealidad del problema es confirmada por el fracaso relativo de Regresión Logística

3. El consumo de combustible determina prácticamente toda la clasificación (80%+)
4. El modelo es robusto: no comete errores críticos, solo en límites de categorías

Interpretación

El Árbol de Decisión captura correctamente la relación física entre consumo de combustible y emisiones de CO₂, generalizando bien a vehículos no vistos durante el entrenamiento.

Mejoras Posibles

Se podrían ajustar los hiperparámetros del árbol (p. ej. limitar `max_depth`, `min_samples_leaf`) mediante validación cruzada; probar ensambles como `RandomForest` para mejorar la precisión.

7. Referencias

<https://www.kaggle.com/datasets/rosemeenshaikh/top-10000-tmdbs-highest-rated-movies>

8. Anexo Distribución de Tareas

Miembro del Equipo	Tareas Realizadas
Antonio García Rodrigo	Pruebas, entrenamiento y rendimiento de modelos
Daniel Martín del Castillo	Elaboración del jupyter notebook
Pol Montero Pons	Diseño y elaboración de la Presentación
David Díaz Gregorio	Redacción de la memoria